Clusterização de formigas: um breve estudo de organização de corpos e dados

Caio M. Carregari[1], Clidenor B. Melo[2]

[1]Universidade do Estado de Santa Catarina (UDESC)
Joinville – SC – Brasil CEP: 89.219.710

{caio.mq.carregari@gmail.com, neto.neto0100@gmail.com}

Abstract. *This paper presents the implementation of a clustering algorithm based on ant behavior (Ant Clustering), inspired by the natural grouping process observed in real colonies. The method uses simple agents that move randomly on a two-dimensional grid, collecting and depositing items according to the density and similarity of the data in their neighborhood. After defining and adjusting the model parameters, experiments demonstrate that the model is capable of organizing initially dispersed data into cohesive clusters. Finally, accuracy and execution time evaluations are presented, discussing the quality and efficiency of the results obtained and future projects.*

Resumo. *Este trabalho apresenta a implementação de um algoritmo de clusterização baseado em comportamento de formigas (Ant Clustering), inspirado no processo natural de agrupamento observado em colônias reais. O método utiliza agentes simples que se movimentam aleatoriamente em uma grade bidimensional, coletando e depositando itens de acordo com a densidade e similaridade dos dados em sua vizinhança. Após a definição e ajuste de parâmetros do modelo, os experimentos demonstram que o modelo é capaz de organizar dados inicialmente dispersos em agrupamentos (Clusters) coesos. Por fim, são apresentadas avaliações de precisão e tempo de execução, discutindo a qualidade e a eficiência dos resultados obtidos e trabalhos futuros.*

1. Introdução

Muitas técnicas de inteligência artificial têm origem na imitação de processos biológicos. Entre elas, a clusterização de formigas destaca-se por reproduzir o mecanismo observado em suas colônias, nas quais os indivíduos cooperam indiretamente para organizar corpos ou larvas em aglomerados. Essa inspiração levou ao desenvolvimento de algoritmos capazes de formar clusters de dados sem conhecimento prévio da estrutura do conjunto analisado.

A ideia foi inicialmente explorada nos anos 1990 em estudos de Inteligência de Enxame, impulsionados pelos trabalhos de Marco Dorigo em otimização por colônias de formigas (*Ant Colony Optimization*). A partir dessa base conceitual, pesquisadores como Lumer e Faieta (1994) propuseram adaptações específicas para tarefas de agrupamento de dados, dando origem a variações do algoritmo e a estudos que investigam sua relação e desempenho em comparação a métodos clássicos como o k-means.

Nesse contexto, este trabalho aplica os princípios da clusterização de formigas, apresentando uma implementação prática do algoritmo e discutindo os resultados obtidos, com ênfase em ajustes de parâmetros, precisão das soluções e tempo de execução.

2. Metodologia e desenvolvimento

O desenvolvimento do trabalho foi realizado em Python, utilizando o VSCode como ambiente de programação. A premissa consiste em criar uma matriz $N \times N$ com bordas conectadas, distribuir corpos – e futuramente dados – e formigas nessa grade, a fim de realizar o agrupamento dos itens seguindo critérios pré-definidos e parâmetros – serão discutidos na seção 3.

Na primeira parte da tarefa, clusterização de dados homogêneos, utilizamos duas simples fórmulas para pegar ou largar o item.

(a) Operação de coleta (pegar item)

- Analisa a posição da formiga, checando se ela está em cima de um item, e não está carregando nada;
- Em seguida, é checado a quantidade de itens vizinhos ao redor do item selecionado;
- Assim, ao saber a quantidade de itens ao redor, executamos a seguinte formula:

$$Ppegar = 1 - \frac{Vizinhosaoredor}{Raiodevisãodaformiga}$$

- A decisão é tomada conforme o valor calculado:
    - Se Ppegar > 0.5, a formiga pega o item;
    - Se Ppegar < 0.5, a formiga não pega o item;
    - Se Ppegar = 0.5, o programa faz uma escolha aleatória entre pegar ou não pegar.

(b) Operação de depósito (largar item)

- Analisa a posição da formiga, checando se ela está em um quadrado vazio e está carregando um item;
- Novamente, é verificado a quantidade de itens vizinhos ao redor da formiga;
- Assim, ao saber a quantidade de itens ao redor, executamos a seguinte formula:

$$Plargar = \frac{Vizinhosaoredor}{Raiodevisãodaformiga}$$

- A decisão segue os mesmos critérios:
    - Se Plargar > 0.5, a formiga larga o item;
    - Se Plargar < 0.5, a formiga não larga o item;
    - Se Plargar = 0.5, a escolha é feita de forma aleatória.

Dessa forma, pela razão dos dados serem homogêneos, as fórmulas – apresentadas em sala pelo professor – adequam-se ao cenário supracitado, capturando o comportamento básico das formigas em relação aos itens, uma vez que, a densidade dos vizinhos é suficiente para promover o agrupamento.

A segunda parte do trabalho envolve diferentes conceitos e fórmulas, visto que os dados passam a ser heterogêneos. Dessa maneira, cada corpo foi substituído por um dado, um vetor bidimensional, com valores definidos por uma média e desvio padrão, com

pesos. Por conseguinte, novas funções foram criadas para realizar o agrupamento desejado.
A lógica de decisão de pegar ou largar um item deixa de ser baseada apenas na densidade de vizinhos e passa a ser fundamentada no conceito de similaridade (f). Essa função avalia o quão semelhante um item é em relação aos dados vizinhos, considerando tanto seus valores no vetor bidimensional quanto seu peso.

O cálculo da similaridade depende da distância Euclidiana média entre o item analisado e seus vizinhos. A distância leva em conta os dois valores do vetor e o peso, que possui uma influência significativa. A fórmula da distância entre dois itens é:

$$D = \sqrt{(X1 - X2)^2 + (Y1 - Y2)^2 + (Z1 - Z2)^2}$$

Em seguida, cada distância d é convertida em uma medida de similaridade local. Para isso, utiliza-se um parâmetro α (Alpha), que funciona como um fator de escala para normalizar a distância. A similaridade parcial com cada vizinho é dada por:

$$F = \sum 1 - \left(\frac{D}{alpha}\right)$$

A função de similaridade final (f) para o item é então calculada como a média das similaridades locais de todos os seus vizinhos.

Em seguida, acontece a normalização do resultado, com a seguinte fórmula:

$$max\,(0.0,\ min(1.0,\ resultado))$$

O modelo também adota um raio de visão variável: caso a formiga encontre três ou menos vizinhos em seu raio inicial, ele é expandido para garantir que o cálculo de f seja baseado em uma amostra mais robusta da vizinhança local.

Com base na similaridade (f), as probabilidades de pegar e largar um item são recalculadas da seguinte forma:

(a) Operação de coleta (pegar item)

A probabilidade de uma formiga pegar um item é inversamente proporcional à similaridade do item com sua vizinhança. Se um item está em um local com outros itens muito diferentes (baixa similaridade), a chance de ser pego aumenta. A decisão é guiada pela seguinte fórmula:

$$Ppegar = \left(\frac{K1}{(K1+f)}\right)^2$$

Onde K1 é uma constante que funciona como um limiar para a decisão de coleta. A formiga pega o item se um número aleatório entre 0 e 1 for menor que Ppegar.

(b) Operação de depósito (largar item)

De forma análoga, a probabilidade de uma formiga largar um item que está carregando é diretamente proporcional à similaridade com os itens da nova vizinhança. Se a vizinhança

é muito parecida com o item carregado (alta similaridade), a chance de largá-lo aumenta. A fórmula utilizada é:

$$\text{Plargar} = \left(\frac{f}{(K2+f)}\right)^2$$

Onde K2 é uma constante que serve como limiar para a decisão de depósito. A formiga larga o item se um número aleatório entre 0 e 1 for menor que Plargar.

Essa nova abordagem, embora computacionalmente mais intensiva, permite ao algoritmo distinguir e agrupar dados heterogêneos com base em suas características intrínsecas, resultando em clusters mais precisos e bem definidos, como será discutido na seção de resultados.

3. Experimentos e resultados obtidos

Para visualizar nossos experimentos, optamos pela visualização da matriz no próprio terminal do Linux (Ubuntu). Para facilitar o entendimento, utilizamos símbolos e cores. As formigas são representadas pela letra 'X' e, quanto estão carregando um item, são representadas pelo símbolo '@'. As bordas da matriz são representadas pelo símbolo '#'. Por fim, os corpos são representados pela letra 'o' e os dados são representados pelo número de seus pesos.

A primeira fase do trabalho se demonstrou mais simples que a segunda, sendo mais rápida para rodar – em torno de 15 a 20 segundos. Dessa forma, optamos por utilizar as seguintes configurações:

- Quantidade de corpos: 140
- Quantidade de formigas: 25
- Tamanho da matriz: 25x25
- Raio de visão das formigas: 1
- Número máximo de iterações: 5.000

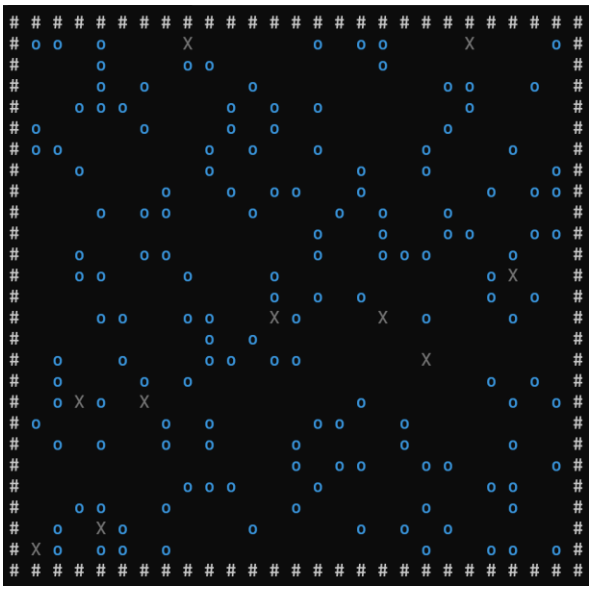

Figura 1. Matriz inicial

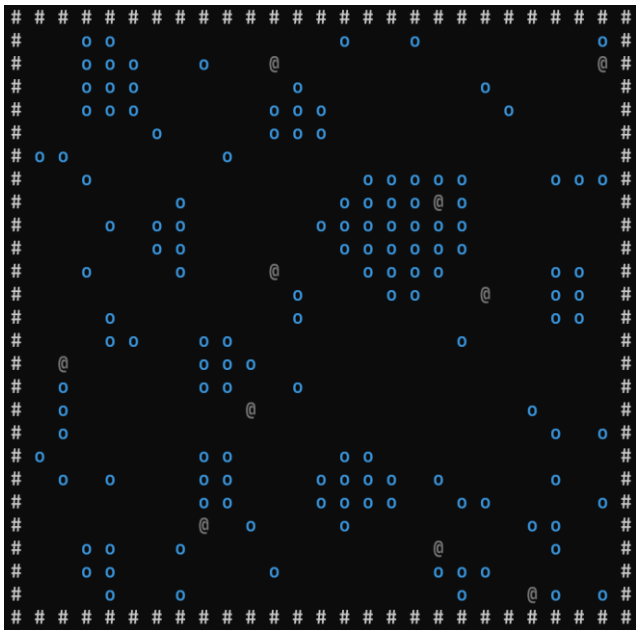

Figura 2. Matriz com 2.500 iterações (metade)

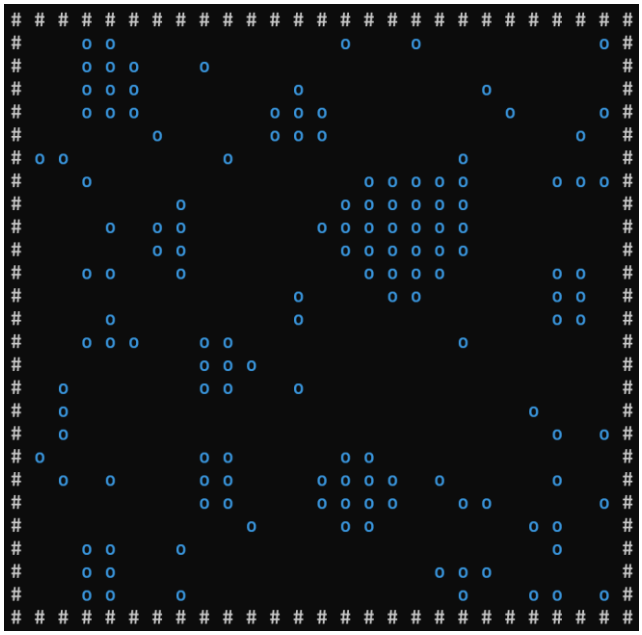

Figura 3. Matriz final com 5.000 iterações

Após alguns testes preliminares, de forma empírica, identificamos que os parâmetros apresentados produziram os melhores resultados. Como esta primeira fase utiliza um critério baseado apenas na densidade da vizinhança, o algoritmo apresenta limitações de precisão, mas forma clusters minimamente coesos.

A segunda parte do trabalho apresentou um processamento mais lento, com tempo médio de aproximadamente duas horas por execução, porém resultou em agrupamentos significativamente mais precisos. Foram realizados dois experimentos, variando a quantidade de dados e de grupos, exigindo o ajuste de alguns parâmetros para cada configuração, a fim de otimizar a formação dos clusters.

(a) Teste com 4 grupos:

- Quantidade de corpos: 400
- Quantidade de formigas: 125
- Tamanho da matriz: 50x50
- Raio de visão das formigas: inicia em 1 e existe a possibilidade de ir até 3 (raio variável)
- Número máximo de iterações: 20.000.000
- Quantidade de grupos: 4
- Alpha: 67
- K1 = 0.01
- K2 = 0.001

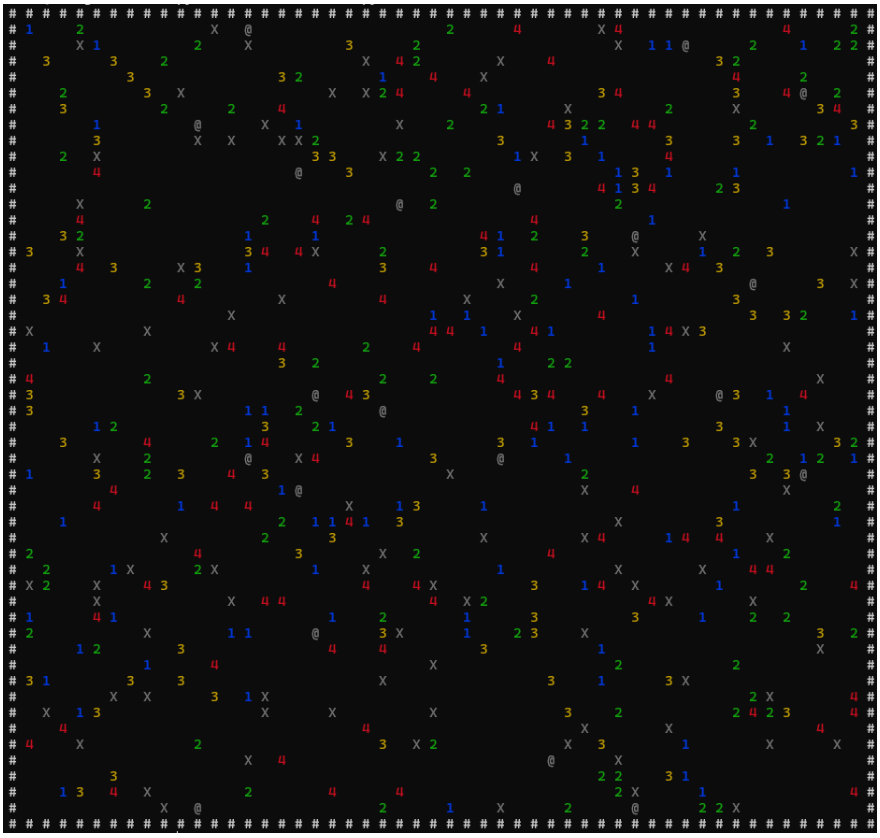

Figura 4. Matriz inicial com 4 grupos

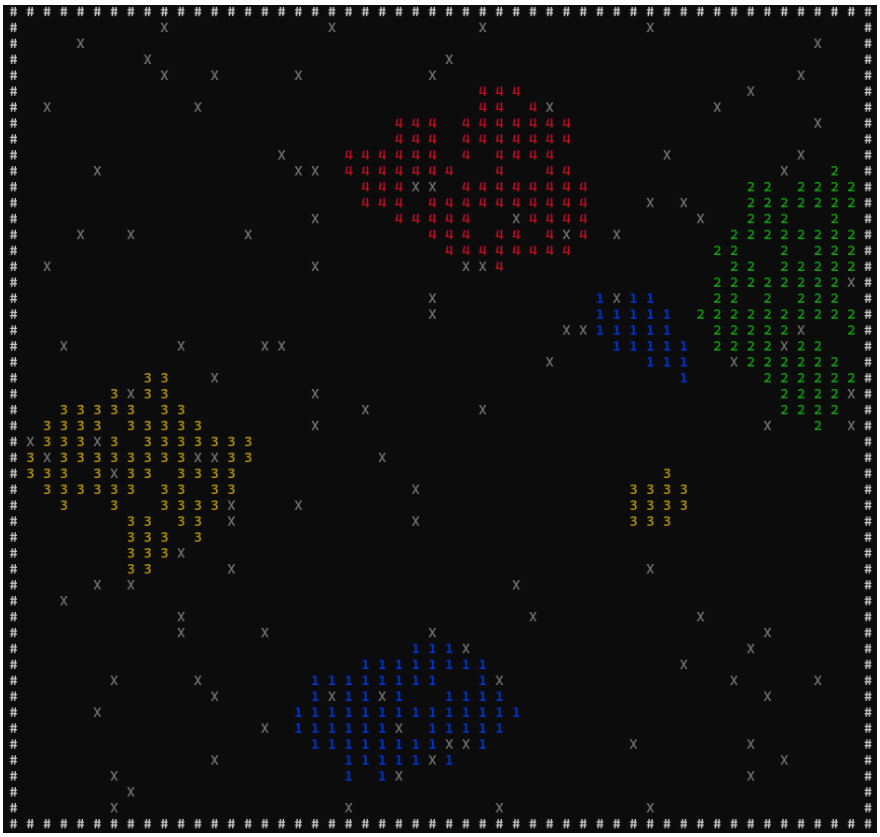

Figura 5. Matriz com 10.000.000 de iterações de 4 grupos (metade)

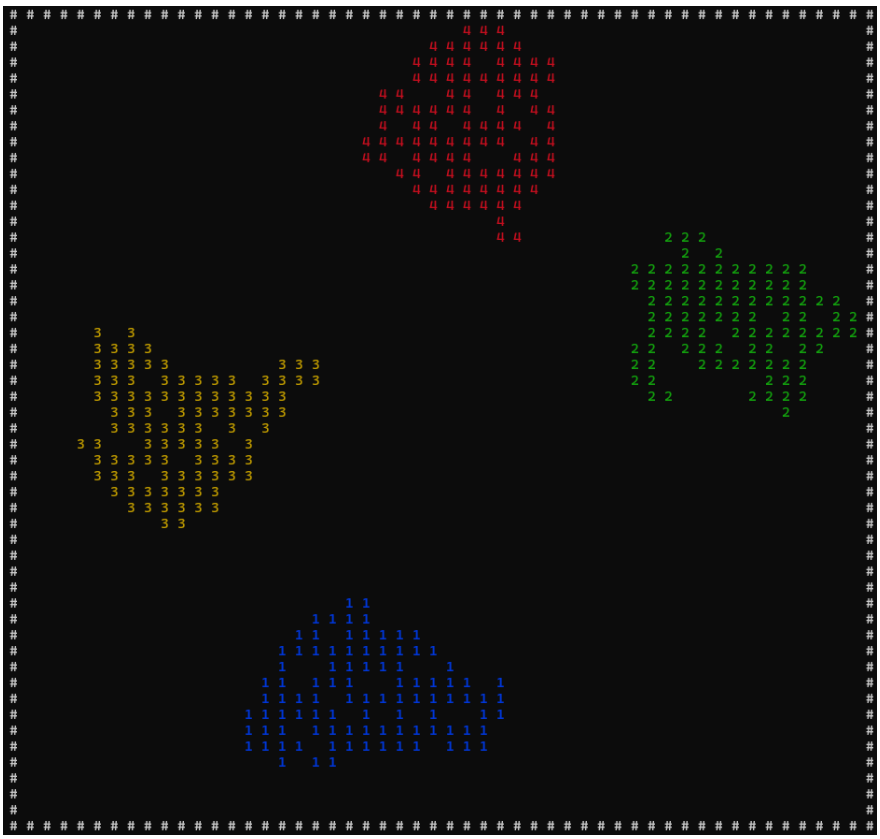

Figura 6. Matriz final com 20.000.000 de iterações de 4 grupos

(b) Teste com 15 grupos:

- Quantidade de corpos: 600
- Quantidade de formigas: 125
- Tamanho da matriz: 80x80
- Raio de visão das formigas: inicia em 1 e existe a possibilidade de ir até 3 (raio variável)
- Número máximo de iterações: 20.000.000
- Quantidade de grupos: 15
- Alpha: 67
- K1 = 0.01
- K2 = 0.001

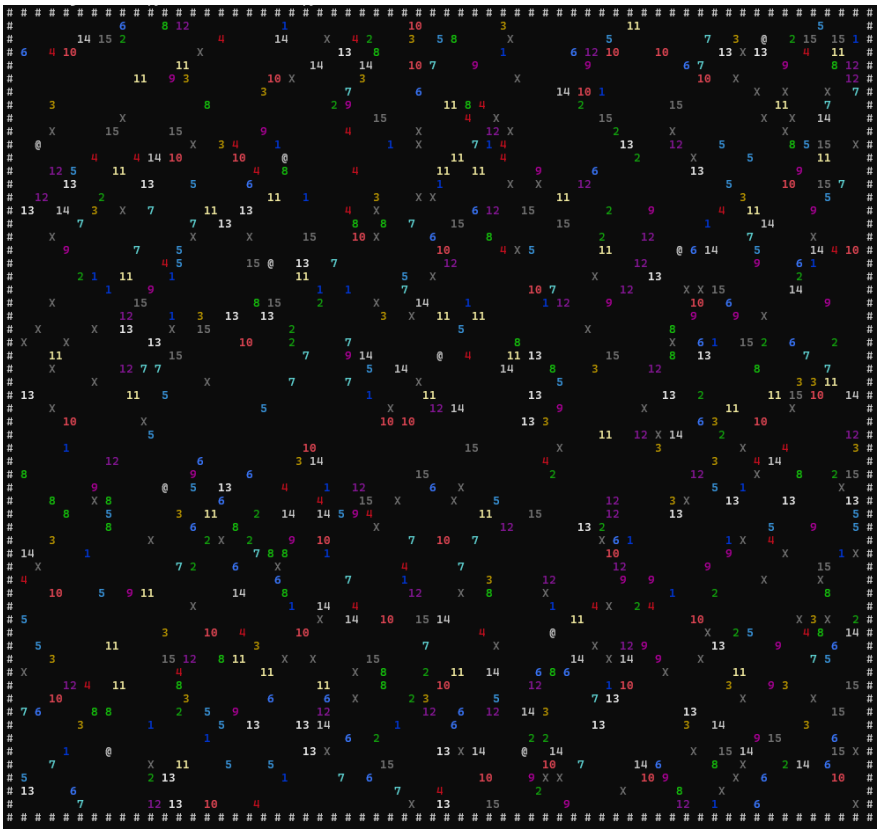

Figura 7. Matriz inicial com 15 grupos

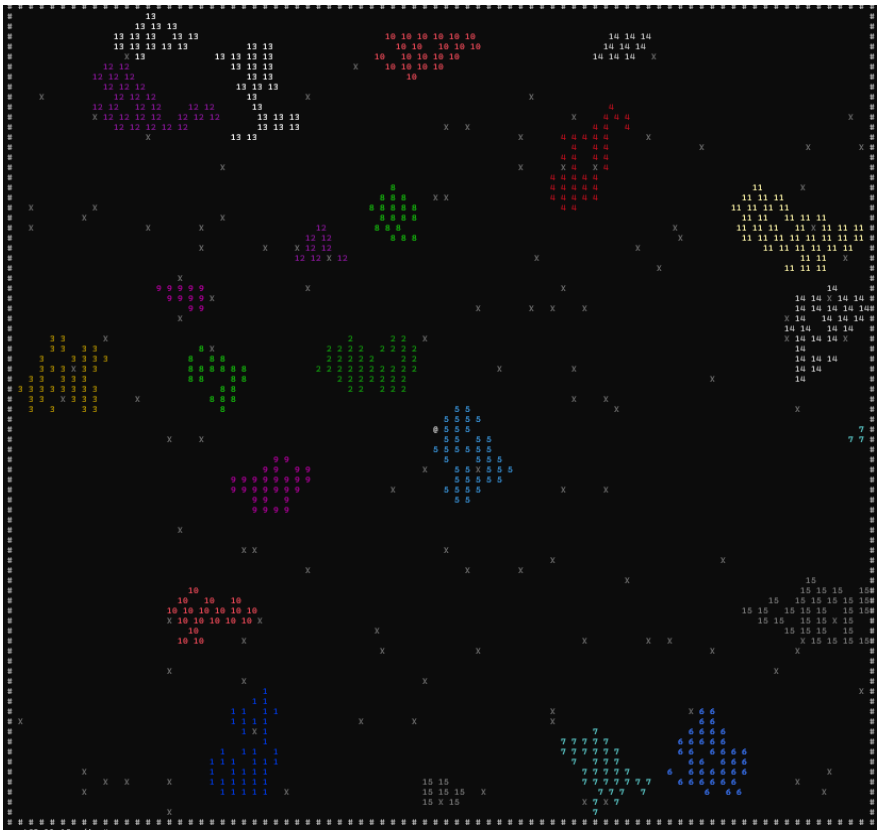

Figura 8. Matriz com 10.000.000 de iterações de 15 grupos (metade)

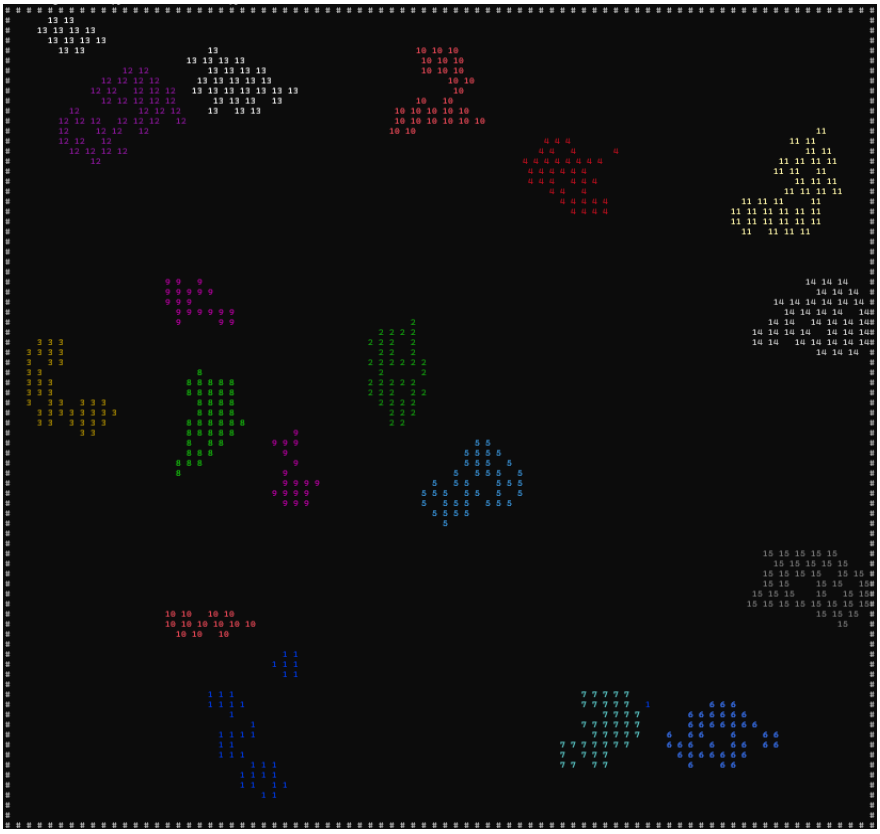

Figura 9. Matriz final com 20.000.000 de iterações de 15 grupos

A definição dos parâmetros teve como referência inicial o trabalho de Knowles e Dorigo (2003), no qual são discutidas fórmulas para favorecer uma clusterização mais estável. Entretanto, alguns valores foram determinados de forma empírica, como o parâmetro α (Alpha). Para estimá-lo, desenvolvemos um código auxiliar em Python capaz de calcular a distância euclidiana média do conjunto de dados. Outro recurso adotado foi o raio variável: ao calcular a quantidade de vizinhos ao redor de uma formiga, caso fossem encontrados três ou menos, o raio de visão era automaticamente ampliado, a fim de verificar a presença de vizinhos adicionais e garantir uma estimativa mais precisa da similaridade local. Além disso, a distância entre os itens considera um terceiro componente, o peso, que exerce forte influência na formação dos clusters: quando o objeto carregado pela formiga possui peso diferente dos vizinhos, essa diferença atua como fator decisivo, reduzindo a probabilidade de largar o item e, caso a formiga não esteja carregando nenhum item, favorece a probabilidade de pegá-lo.

4. Análise dos resultados

Nessa seção iremos discutir os resultados, apontando os acertos e falhas. Na primeira parte do trabalho, onde foi trabalhado com dados homogêneos, podemos caracterizar o resultado como satisfatório, já que conseguiu agrupar itens em clusters coesos em um tempo relativamente curto, facilitando a quantidade de testes feitos. Contudo, por depender de poucos parâmetros e pouco refinamento, a precisão é a principal desvantagem desse teste, e a aleatoriedade ainda exerce influência significativa no resultado final.

Na segunda parte do trabalho, onde os dados passaram a ser heterogêneos, os resultados obtidos foram muito superiores quando comparados a primeira parte. Na clusterização de quatro grupos, obtivemos um resultado perfeito, onde todos os elementos estavam devidamente separados em quatro grandes grupos. No teste feito com 15 grupos, apesar de maior complexidade, o resultado foi quase impecável, com a maioria dos clusters claramente definidos. Contudo, mesmo os resultados da segunda parte se sobressaírem quando comparados a primeira, o principal problema gira em torno da otimização do código. Como foi comentado na seção três, o tempo médio de concluir um teste para essa parte do trabalho, demorou cerca de duas horas. Dessa forma, o principal problema já não é a aleatoriedade, mas sim a capacidade de construir um algoritmo bom o suficiente que execute em um tempo mais viável.

5. Conclusão e futuras pesquisas

Neste trabalho foi realizada uma análise do processo de clusterização de dados baseado no comportamento de formigas, abordando desde seus princípios biológicos até a implementação prática em Python.

Foram conduzidos dois experimentos: a primeira etapa do projeto consistia em organizar dados homogêneos e, apesar de formar clusters coesos em um curto período de tempo, a precisão demonstrou ser limitada. A segunda etapa, embora mais complexa e custosa computacionalmente, mostrou resultados mais precisos e coesos, tanto para o agrupamento de quatro grupos, quanto para o de 15.

Dessa forma, ao fazer a avaliação, podemos notar que a definição dos parâmetros – como raio, tamanho da matriz e constantes – é fundamental para garantir resultados consistentes. Contudo, os testes também revelaram que a eficiência computacional é o principal desafio para poder aplicar esse tipo de algoritmo em uma larga escala, e de forma viável.

Por fim, como trabalhos futuros, destaca-se a possibilidade de otimizar o código para reduzir o tempo de execução e explorar variações do algoritmo, podendo incluir a implementação de heurísticas para reduzir seu custo computacional. Um exemplo de heurística a ser implementada é ressaltada por Boryczka (2008), destacando a introdução de feromônios, e como as formigas se comportariam em grandes bases de dados. Em suma, este trabalho demonstra que a inspiração em comportamentos naturais continua sendo uma importante ferramenta para resolver problemas complexos, atuando em áreas completamente distintas.

Referências

Boryczka, U. (2008) *Ant clustering algorithm*. *Intelligent Information Systems*, pp. 455–458.

Knowles, J. and Dorigo, M. (2003) *Ant-based clustering: A comparative study of its relative performance with respect to k-means, average link and 1D-SOM*.

Lumer, E. and Faieta, B. (1994) *Diversity and adaptation in populations of clustering ants*. In *Proceedings of the Third International Conference on Simulation of Adaptive Behavior*, pp. 501–508. MIT Press. ISBN 0-262-53122-4.

Ramakrishnan, S. (2010) *Ant-based clustering algorithms: A brief survey*. *International Journal of Computer Theory and Engineering (IJCTE)*, Vol. 2, pp. 787–796. DOI: https://doi.org/10.7763/IJCTE.2010.V2.242